

Ford 엔진

시계열 데이터 분석

1조

202121628 박정현

202121639 양호용

202121619 김태훈

목차

01 데이터 개요

02 전처리

03 모델별 결과분석

04 결론

데이터 Ford engine data

데이터 형태

label	time_1	time_2	time_3	time_4	time_5	time_6		time_500
-1 / 1	y_1	y_2	y_3	y_4	y_5	y_6		y_500

- 엔진 이상을 분류하는 task (lable: -1/1)
- col 1-500 은 실험 환경에서 측정된 연속적 데이터

데이터 Ford 엔진 데이터

Ford A

Train : [3601, 500]

Test: [1320, 500]

Ford B

Train : [3636, 500]

Test: [810, 500]

- Ford B는 Ford A보다 노이즈 심한 데이터
- 결측치 처리, 정규화 등 기본적 전처리가 완료된 상태

데이터 전처리 - pca

```
pca = PCA(n_components=0.95, random_state=42)
```

sklearn pca사용

```
ford_A_shape (3601, 500)  
after_PCA_shape: (3601, 66)
```

```
ford_B_shape (3636, 500)  
after_PCA_shape: (3636, 72)
```

- 500차원에서 각각 66, 72차원으로 압축

데이터 전처리 - Feature Engineering

기본통계 기반

피처	의미
mean, median	전체 평균/중앙값
std	진폭의 변동성
min, max	순간 최대/최소 진동
p10, p90	상하위 10% quantile
iqr	중간 50% 구간 폭
skew	비대칭성
kurtosis	꼬리 두께(피크)

변화율 기반

피처	의미
diff_mean	변화량 평균
diff_std	변화량의 분산
diff_abs_mean	절대 변화량 평균
zero_crossings	부호 변화 횟수

시계열 반영 주파수

피처	의미
spec_centroid	스펙트럼 중심
spec_entropy	잡음/불규칙도
dom_freq	지배 주파수
dom_power	지배 주파수 세기

데이터 전처리-Feature Engineering

raw data의 통계, 변화율, 주기성을 추출하여 피쳐 생성

```
std=float(np.std(x,ddof=1)) if n>1 else 0.0,  
min=float(np.min(x)), max=float(np.max(x)),  
median=float(np.median(x)),  
p10=float(np.quantile(x,0.10)),  
p90=float(np.quantile(x,0.90)),  
iqr=float(np.quantile(x,0.75)-np.quantile(x,0.25)),  
skew=np_skew(x), kurtosis=np_kurt(x),
```

통계

```
zc=np.where(np.diff(np.signbit(x)))[0]; feat["zero_crossings"]=int(len(zc))  
dx=np.diff(x); dx = dx if dx.size else np.array([0.0])  
feat.update(dict(  
    diff_mean=float(np.mean(dx)),  
    diff_std=float(np.std(dx,ddof=1)) if dx.size>1 else 0.0,  
    diff_abs_mean=float(np.mean(np.abs(dx))),
```

변화율

```
def acf(arr,lag):  
    if lag<=0 or lag>=arr.size: return 0.0  
    a=arr-arr.mean(); d=float((a*a).sum()+1e-12)  
    return float(np.dot(a[:-lag],a[lag:])/d)  
for lag in (1,5,10,20,50): feat[f"acf_lag{lag}"]=acf(x,lag)  
t=np.arange(n); slope=float(np.polyfit(t,x,1)[0]) if n>=2 else 0.0; feat["slope"]=slope  
X=np.fft.rfft(x-x.mean()); f=np.fft.rfftfreq(n,d=1.0/fs); mag=np.abs(X); ps=mag**2  
pss=float(ps.sum()+1e-12); centroid=float((f*ps).sum()/pss); p=ps/pss  
entropy=float(-(p*np.log(p+1e-12)).sum())  
if mag.size>1: idx=int(np.argmax(mag[1:])+1); dom_freq=float(f[idx]); dom_power=float(mag[idx])  
else: dom_freq=dom_power=0.0  
feat.update(dict(spec_centroid=centroid, spec_entropy=entropy, dom_freq=dom_freq, dom_power=dom_power))  
return feat
```

주기성

500 col → 24 col

Linear

Logistic regression
Linear SVM

Non-linear

SVM (RBF)

Bagging

Random Forest

Boosting

GBDT
Light GBM
XGboost

Raw

PCA

Feature Engineering



모델 비교분석



솔루션 도출

Raw 모델별 결과

Ford A

model	AUC	PR-AUC	F1@0.5	F1@best	thr*
SVM (RBF)	<u>0.902822</u>	<u>0.898330</u>	<u>0.832407</u>	<u>0.835012</u>	<u>0.461499</u>
LightGBM	0.896829	0.892413	0.809258	0.821717	0.367127
XGBoost	0.885545	0.880362	0.813135	0.822086	0.476260
Random Forest	0.839096	0.824009	0.762658	0.772161	0.479375
GBDT	0.690003	0.648076	0.606409	0.688273	0.385272
Logistic Regression	0.487130	0.451020	0.467305	0.660052	0.318964
Linear SVM	0.472572	0.436998	0.000000	0.661061	0.484186

Ford B

model	AUC	PR-AUC	F1@0.5	F1@best	thr*
SVM (RBF)	<u>0.761239</u>	<u>0.743381</u>	<u>0.709914</u>	<u>0.727876</u>	<u>0.353924</u>
LightGBM	0.750154	0.750882	0.701796	0.716685	0.394389
XGBoost	0.744471	0.750638	0.684706	0.717256	0.397103
Random Forest	0.707196	0.701276	0.625668	0.700291	0.429792
GBDT	0.628606	0.617535	0.617169	0.685185	0.409514
Linear SVM	0.487528	0.489706	0.000000	0.673823	0.481198
Logistic Regression	0.479968	0.486213	0.483354	0.672145	0.293833

PCA 모델별 결과

Ford A

model	AUC	PR-AUC	F1@0.5	F1@best	thr*
SVM (RBF)	<u>0.957579</u>	<u>0.959841</u>	<u>0.894118</u>	<u>0.895430</u>	<u>0.461432</u>
LightGBM	0.945889	0.943964	0.872441	0.874411	0.464663
XGBoost	0.942341	0.939469	0.860780	0.863741	0.400461
GBDT	0.914742	0.910346	0.818695	0.836018	0.401470
Random Forest	0.912002	0.909257	0.832679	0.836115	0.469321
Logistic Regression	0.494150	0.478803	0.456140	0.652374	0.224913
Linear SVM	0.491574	0.480163	0.185279	0.652374	0.437619

Ford B

model	AUC	PR-AUC	F1@0.5	F1@best	thr*
LightGBM	<u>0.839076</u>	<u>0.845996</u>	<u>0.763321</u>	<u>0.767221</u>	<u>0.389991</u>
XGBoost	0.834064	0.840820	0.748466	0.765086	0.317313
GBDT	0.819019	0.833060	0.738426	0.746988	0.470611
SVM (RBF)	0.816053	0.800203	0.752638	0.772829	0.397898
Random Forest	0.813858	0.822972	0.736591	0.757158	0.425375
Logistic Regression	0.503314	0.515011	0.465116	0.671042	0.290477
Linear SVM	0.486394	0.501781	0.000000	0.671593	0.479148

피쳐엔지니어링 모델별 결과



Ford A

model	AUC	PR-AUC	F1@0.5	F1@best	thr*
XGBoost	<u>0.9718</u>	<u>0.9723</u>	<u>0.9139</u>	<u>0.9156</u>	<u>0.495</u>
Linear SVM	0.9718	0.9671	0.9129	0.9193	0.365
Logistic Regression	0.9712	0.9664	0.9119	0.9181	0.343
LightGBM	0.9708	0.9712	0.9081	0.9099	0.467
GBDT	0.9698	0.9699	0.9060	0.9104	0.547
SVM (RBF)	0.9647	0.9640	0.8989	0.9002	0.475
Random Forest	0.9582	0.9604	0.8852	0.8887	0.463

Ford B



model	AUC	PR-AUC	F1@0.5	F1@best	thr*
Logistic Regression	<u>0.8688</u>	<u>0.8643</u>	<u>0.7859</u>	<u>0.7980</u>	<u>0.581</u>
Linear SVM	0.8679	0.8663	0.7907	0.7970	0.577
LightGBM	0.8665	0.8819	0.7886	0.7907	0.407
XGBoost	0.8623	0.8795	0.7815	0.7911	0.334
GBDT	0.8520	0.8691	0.7654	0.7698	0.560
SVM (RBF)	0.8419	0.8665	0.7586	0.7680	0.355
Random Forest	0.8335	0.8593	0.7633	0.7670	0.457

전처리 방식 별 비교



- Raw → PCA → FE 순으로 성능 상승
- FE적용하자 모델의 평균 성능이 크게 상승
- 평균 상승의 원인 분석을 위해 모델 그룹 별 결과 분석

모델별 결과 비교



- Raw/PCA에서 선형모델은 낮은 성능을 보임.
- PCA 적용 후 부스팅 모델 성능 향상.
- FE 적용 후 선형 모델 성능이 크게 상승. -> FE를 통해 task가 선형 분리 가능해진 것으로 보임.

전처리 방식 별 비교 (FE) 성능

모델	1위	2위	3위	4위	5위
Random Forest	<u>acf_lag10</u>	acf_lag50	diff_std	acf_lag5	dom_freq
GBDT	<u>acf_lag10</u>	acf_lag50	acf_lag5	dom_freq	acf_lag20
XGBoost	<u>acf_lag10</u>	acf_lag50	dom_freq	acf_lag5	spec_entropy
LightGBM	<u>acf_lag10</u>	acf_lag20	acf_lag5	acf_lag50	dom_power
Logistic Regression(+)	<u>acf_lag1</u>	spec_entropy	dom_power	spec_centroid	max
Logistic Regression(-)	<u>acf_lag10</u>	acf_lag5	acf_lag20	acf_lag50	dom_freq

분석 결과

고차원 시계열 데이터인 Ford 엔진 결함 진단에 있어 성능을 결정짓는 핵심 요인은 복잡한 모델링이 아닌 적합한 데이터 전처리를 알 수 있었다.

best AUC : Feature Engineering(ford $\alpha = 0.9716$ / ford $b = 0.8688$).

시계열 데이터의 특성을 유지하는 전처리를 적용하는 것이 그렇지 않은 방식보다 좋은 결과를 얻을 수 있었다.

test 데이터를 분석하여 특성에 맞는 적절한 전처리 방식을 적용하는 것이 중요하다.

Q&A



감사합니다.